

Análise de desempenho de Jogadores de Futebol com Grafos: Um Algoritmo para Time Ideal da Temporada

Sergio Henrique Quedas Ramos

Department of Computer Science, Federal Center of Technological Education of Minas Gerais

Minas Gerais, Brazil

sergio@aluno.cefetmg.br

Abstract—The performance analysis of football players based on statistics has become increasingly relevant in the football world, driven by advances in sports network analysis algorithms and the greater availability of statistical data. This study utilizes graph theory to select the best players in specific positions, forming an optimized team. To achieve this, we analyze statistics from the 2022/2023 European season, grouping players into subgraphs based on their positions. The evaluation considers performance, similarity, and connectivity, identifying the athletes who stand out the most. The results indicate the formation of a balanced team with high potential for success in prestigious European competitions.

Index Terms—Performance analysis, Football players, Graph theory, Sports network analysis, Player selection, Similarity, Connectivity, Ideal team.

I. INTRODUÇÃO

O futebol é um esporte globalizado que continuamente integra diferentes estilos de jogo e culturas dentro de suas equipes e competições, [1]. Nesse cenário, é notório que, em clubes europeus, onde circula a maior quantidade de recursos financeiros, estão os melhores jogadores provenientes dos mais diversos países. Essa diversidade de talentos, aliada à crescente evolução das estratégias e exigências táticas no futebol moderno, torna ainda mais complexa a tarefa de avaliar o desempenho dos jogadores e determinar quem são os melhores ao longo de uma temporada.

A temporada 2022/2023, em particular, trouxe consigo desafios inéditos, com um calendário apertado e a competição de jogadores de diferentes origens, estilos de jogo e níveis de experiência. Além disso a disparidade financeira entre os clubes aumentou, com um pequeno grupo dominando a geração de receitas, o Colégio de Economistas da Catalunha apresentou um estudo que analisa a situação financeira das cinco principais ligas europeias - a Premier League inglesa, a Bundesliga alemã, a Liga Espanhola, a Serie A Italiana e a Ligue 1 francesa com dados da temporada 2022/2023 [2].

Dessa forma determinar os melhores jogadores dessa temporada vai além de observações subjetivas de fãs e técnicos. É necessário um método robusto e preciso que leve em consideração uma série de fatores quantitativos, como gols, assistências, desarmes, posicionamento e contribuição coletiva para a equipe. No entanto, a diversidade de estilos de jogo e

a interdependência entre as funções de cada jogador tornam essa tarefa ainda mais desafiadora.

Para enfrentar esse problema, propomos um algoritmo baseado em grafos para identificar os melhores jogadores da temporada 2022/2023 e construir uma equipe otimizada. Nossa abordagem avalia o desempenho individual e as similaridades de jogadores de alta performance para montar um time coletivo, com alta sintonia. Por meio de uma rede de equações e grafos, analisamos a importância e contribuições de cada jogador para sua equipe, buscando identificar os jogadores mais impactantes dos clubes em geral em suas respectivas posições. Analisando de uma forma que eles também contenham uma similaridade garantindo que os jogadores selecionados compartilhem atributos semelhantes, evitando desalinhamentos táticos na formação final. Assim este estudo tem como objetivo não apenas classificar os jogadores com base no desempenho estatístico, mas também formar uma equipe com compatibilidade técnica e coesão estratégica.

Através desse algoritmo, pretende-se oferecer uma análise objetiva e inovadora, contribuindo para uma compreensão mais profunda dos fatores que determinam o melhor time em uma temporada de futebol. Nas seções seguintes, é apresentado os detalhes do desenvolvimento desse algoritmo (II e III) e os resultados obtidos, com uma análise das implicações para o futuro da avaliação de jogadores no esporte(IV).

II. TRABALHOS CORRELATOS

A aplicação de modelos computacionais para análise de desempenho em esportes de alto rendimento tem se consolidado como uma abordagem essencial para a avaliação de atletas. Estudos de diferentes áreas convergem para a busca de resultados mais precisos, tornando indispensáveis ferramentas que aceleram o processo de análise. Rein, R., & Memmert, D. (2016) [3] discute sobre o impacto da ciência de dados na análise tática do futebol, destacando a necessidade de modelos computacionais para lidar com a complexidade do jogo. No futebol, a necessidade de processar grandes volumes de dados torna crucial o auxílio na interpretação das estatísticas, considerando as particularidades de cada posição e função desempenhada em campo.

Nessa conjuntura, Mendes-Neves, Meireles e Mendes-Moreira (2022) [4] investigaram a evolução do desempenho

de jogadores de futebol ao longo do tempo, permitindo uma compreensão mais profunda da consistência de cada atleta durante a temporada. O estudo utilizou os modelos I-VAEP e O-VAEP, que empregam equações próprias para calcular o valor das ações individuais dos jogadores ofensivamente e defensivamente, gerando resultados relevantes sobre os melhores desempenhos e suas respectivas trajetórias ao longo da competição.

Apesar da eficácia dos modelos estatísticos tradicionais na quantificação do desempenho individual, eles não capturam completamente a dinâmica coletiva e a interconexão entre os jogadores. Nesse sentido, Duch, Waitzman e Amaral (2010) [5] propuseram um modelo baseado em redes para quantificar a influência dos jogadores dentro de uma equipe. O estudo analisou as interações entre atletas durante a Eurocopa 2008, utilizando métricas de centralidade para identificar os jogadores mais impactantes. Os resultados demonstraram que atletas com alta centralidade de fluxo desempenham papéis fundamentais na dinâmica coletiva da equipe, indo além das métricas tradicionais de desempenho individual.

Nesse contexto, metodologias baseadas em estatísticas avançadas e análise estrutural de redes podem ser adaptadas para avaliar o impacto individual dos jogadores de maneira mais precisa dentro de um cenário competitivo. Com base nesses princípios, desenvolvemos a combinação de técnicas estatísticas avançadas, como os modelos I-VAEP e O-VAEP, com abordagens estruturais da Teoria dos Grafos, como as métricas de centralidade e similaridade proporcionando uma visão mais abrangente do desempenho dos jogadores. Essa integração permite análises mais detalhadas sobre o impacto individual e conexão dos atletas, contribuindo para estratégias mais eficazes na formação de equipes competitivas.

Dessa forma, este estudo trouxe a integração entre estatísticas avançadas e análise de redes complexas que possibilita uma avaliação mais robusta e realista do desempenho esportivo. Ao levar em conta não apenas os números individuais, mas também a interação entre jogadores de características semelhantes. Estratégia eficaz na formação de equipes competitivas, equilibradas e eficientes.

III. METODOLOGIA

Estudos como o Felipe Werneck de Oliveira Mendes, Thiago Magela Rodrigues Dias, Alisson Marques da Silva, André Luis Maravilha Silva, Michel Pires da Silva(2024) [6] utilizaram base de dados para analisar os desempenhos de jogadores relacionados a diferentes técnicos e posições táticas. Entretanto, não analisaram os desempenhos individuais dos jogadores, quando comparado a outros jogadores da mesma posição na temporada.

A. Base de Dados

Para isso nesse presente estudo, foi utilizado uma base de dados [7] na qual contém estatísticas individuais de cada jogador da temporada de 2022/2023 das 5 principais ligas do futebol Europeu. Estatísticas, essas usadas:

TABLE I
ESTATÍSTICAS UTILIZADAS.

Nome	Significado
Player	Nome do jogador
Pos	Posição
Comp	Liga
Min	Minutos Jogados
Goals	Gols
G/Sh	Gols por chute
ShoPK	Gols de pênalti
PasTotCmp%	Porcentagem de passes completos
Assists	Assistências
PasAss	Passes antes da assistência
SCA	Ações que resultam chutes
GcaDrib	Dribles bem sucedidos
TkIDri%	Porcentagem de desarmes ganhos
Int	Interceptações
Err	Erros que levam a chute do adversário
ToTk1%	Porcentagem de desarmes tomados
CarPrgDist	Distância percorrida com a bola
Fls	Faltas cometidas
CrdR	Cartão Vermelho
CrdY	Cartão Amarelo
AerWon%	Porcentagem de lances ganhos pelo alto
Crs	Cruzamentos
GcaFld	Faltas cometidas que levam a um gol
Recov	Numero de bolas perdidas recuperadas

Para análise de todos esses dados estatísticos de forma coesa foi necessário primeiramente um tratamento de dados, excluindo colunas não utilizadas, usando a biblioteca *Pandas* para isso, considerando apenas os que são mais uteis para cada posição descartando colunas que não interessa como distancia de passes realizados.

A posição DFFW, durante o tratamento de dados, foi desconsiderada. Isso pois uma posição que no dataset juntou jogadores de diferentes posições e com pouca relevância para o resultado. Consequentemente atrapalhando na formação do resultado final, por isso não foi utilizada na criação dos grafos nem na métrica das equações de desempenho.

B. Equações de Desempenho

Dessa forma seguindo uma ideia utilizada por Gustavo Henrique D’Anunciação Ferreira (2023) [8] e [4], os dados foram utilizados em equações as quais colocam peso em ações de diferentes jogadores baseado em sua posições e necessidades de melhores técnicas. Para isso foram excluídos jogadores com menos de 400 minutos jogados na temporada, uma vez que jogadores com menos de 4 partidas e meia na temporada não são relevantes para o estudo. Dessa forma, as equações ficaram:

Goleiro (GK):

$$D = 2 \cdot \text{AerWon\%} + 1.2 \cdot \text{PasTotCmp\%} + 3 \cdot \text{Recov} - 3 \cdot \text{Err} - 2 \cdot \text{CrdR} - 1.5 \cdot \text{CrdY} - 2.5 \cdot \text{GcaFld} \quad (1)$$

Zagueiro (DF):

$$D = 5.5 \cdot \text{TklDri\%} + 3.5 \cdot \text{Int} + 3.2 \cdot \text{ToTkl\%} + 3 \cdot \text{AerWon\%} \\ + 1.8 \cdot \text{Recov} + 2.2 \cdot \text{CarPrgDist} - 2 \cdot \text{Err} - 3 \cdot \text{CrdR} \\ - 1.5 \cdot \text{CrdY} - 0.5 \cdot \text{Fls} - 1.8 \cdot \text{GcaFld} + 1.2 \cdot \text{PasTotCmp\%} \quad (2)$$

Lateral (DFMF):

$$D = 3 \cdot \text{TklDri\%} + 2 \cdot \text{Int} + \text{AerWon\%} + 1.2 \cdot \text{Recov} \\ - 1.5 \cdot \text{Err} - 2 \cdot \text{CrdR} - 1.1 \cdot \text{CrdY} + 1.8 \cdot \text{Crs} \\ - 0.3 \cdot \text{Fls} - 1.1 \cdot \text{GcaFld} + 1.4 \cdot \text{PasAss} \\ + 1.2 \cdot \text{PasTotCmp\%} + 1.5 \cdot \text{Assists} + 1.2 \cdot \text{CarPrgDist} \\ + 1.3 \cdot \text{SCA} \quad (3)$$

Meia Atacante/Ponta (MFDF):

$$D = 3 \cdot \text{Goals} + \text{G/Sh} + 1.5 \cdot \text{ShoPK} + 1.5 \cdot \text{SCA} \\ + \text{PasTotCmp\%} + 1.8 \cdot \text{Assists} - 2 \cdot \text{CrdR} - 0.8 \cdot \text{CrdY} \\ + 1.5 \cdot \text{GcaDrib} + 1.5 \cdot \text{ShoPK} + 1.2 \cdot \text{CarPrgDist} \quad (4)$$

Meio Campo Central (MF):

$$D = 2 \cdot \text{PasTotCmp\%} + 3.7 \cdot \text{Assists} + 1.8 \cdot \text{SCA} \\ + 1.1 \cdot \text{Recov} + 1.6 \cdot \text{GcaDrib} - 1.2 \cdot \text{Err} \\ - 0.9 \cdot \text{CrdY} + 2.5 \cdot \text{Goals} + 1.1 \cdot \text{CarPrgDist} \\ + 1.4 \cdot \text{PasAss} - 0.8 \cdot \text{ToTkl\%} - 0.2 \cdot \text{Fls} \\ - 2 \cdot \text{CrdR} \quad (5)$$

Atacante Centroavante (FW):

$$D = 5 \cdot \text{Goals} + 1.5 \cdot \text{G/Sh} + 1.5 \cdot \text{ShoPK} + 1.5 \cdot \text{SCA} \\ + 1.3 \cdot \text{Assists} - 2 \cdot \text{CrdR} - 0.9 \cdot \text{CrdY} \\ + 1.5 \cdot \text{GcaDrib} + 1.5 \cdot \text{ShoPK} \quad (6)$$

Meio Campo/Atacante (MFFW):

$$D = 4.7 \cdot \text{Goals} + 1.5 \cdot \text{PasTotCmp\%} + 3 \cdot \text{Assists} + 2 \cdot \text{SCA} \\ + 1.3 \cdot \text{GcaDrib} + 1.7 \cdot \text{CarPrgDist} - 0.3 \cdot \text{CrdY} \\ - 0.6 \cdot \text{ToTkl\%} - 0.2 \cdot \text{Fls} - 2 \cdot \text{CrdR} + 1.2 \cdot \text{PasAss} \quad (7)$$

Meia Atacante/Centroavante (FWDF):

$$D = 2 \cdot \text{Goals} + \text{G/Sh} + 1.5 \cdot \text{ShoPK} \\ + 1.5 \cdot \text{SCA} + \text{PasTotCmp\%} + 1.3 \cdot \text{Assists} \\ - 2 \cdot \text{CrdR} - 1.2 \cdot \text{CrdY} \quad (8)$$

Atacante Rápido/Meia (FWMF):

$$D = 3.5 \cdot \text{Goals} + 1.7 \cdot \text{SCA} + 1.1 \cdot \text{PasTotCmp\%} \\ + 2 \cdot \text{Assists} - 2 \cdot \text{CrdR} - 0.7 \cdot \text{CrdY} \\ + 1.4 \cdot \text{GcaDrib} + 1.2 \cdot \text{CarPrgDist} - 0.8 \cdot \text{ToTkl\%} \quad (9)$$

Com base nessas equações, é notório que posições mais defensivas tiveram maior ênfase de peso em dados como: desarmes, lances ganhos pelo alto, interceptações, faltas cometidas e erros. Enquanto posições mais ofensivas teve maior ênfase em gols, assistências, dribles, chutes para o gol e distância percorrida com a bola. Além disso, teve a busca

por jogadores mais equilibrados para compor as laterais. Entretanto, é perceptível que a busca foi realizada tentando encontrar um time ideal com características mais ofensivas.

C. Ponderação das Ligas

Ao final, essas equações foram ponderadas de acordo com a liga que o atleta atua por meio de uma métrica realizada com base em dados retirados no Globo Esporte, (2023) [9] levantamento, feito pela IFFHS, a Federação Internacional de História e Estatísticas do Futebol, janeiro de 2023. O ranking trouxe Premier League (1.086), Campeonato Espanhol (967,5), Campeonato Alemão (921,5), Campeonato Italiano (866), Campeonato Francês (855), sendo que o campeonato brasileiro o qual ficou em primeiro não foi utilizado para a realização desse estudo. Dessa maneira a métrica utilizada foi

$$M_i = \frac{V_i}{V_{\min}} \quad (10)$$

Onde:

- M_i é a métrica da liga i ;
- V_i é o valor atual da liga i ;
- V_{\min} é o menor valor entre todas as ligas comparadas.

Resultando em:

TABLE II
MÉTRICAS CALCULADAS PARA CADA LIGA.

Liga	Métrica
Premier League	1.27
La Liga	1.13
Bundesliga	1.08
Série A	1.01
Ligue 1	1.00

O cálculo final de desempenho de cada jogador por posição ficou como $PesoLiga * Desempenho$. O resultado foi normalizado usando o *MinMaxScaler* da biblioteca *sklearn.preprocessing*, para não ter discrepância e os dados serem analisados com sucesso.

D. Similaridade Cosseno

Com base nesses dados obtidos foi utilizada a Teoria dos Grafos, onde cada posição foi separada em um subgrafo onde os nós são os jogadores daquela posição e as arestas de conexão calculadas pela similaridade cosseno. Por meio da biblioteca *sklearn.metrics.pairwise* utilizando o algoritmo *cosine_similarity*. A similaridade do cosseno entre dois vetores A e B é definida como:

$$S(A, B) = \frac{A \cdot B}{\|A\| \|B\|} \quad (11)$$

Onde:

- $A \cdot B$ é o produto escalar dos vetores A e B ;
- $\|A\|$ e $\|B\|$ são as normas euclidianas dos vetores A e B , respectivamente.

No estudo, esses vetores são utilizados a partir da métrica de desempenho calculada pelas fórmulas matemáticas supracitadas. A similaridade varia entre 0 e 1, onde valores mais

próximos de 1 indicam maior similaridade entre os vetores. E caso tenha uma similaridade maior que 0.1 arestas são criadas entre os nós(jogadores) da mesma posição, esse procedimento é realizado para todos os nós de cada subgrafo.

E. Busca do Time Ideal

Neste momento, para encontrar os melhores jogadores de cada subgrafo foi utilizado um procedimento onde são escolhidos 11 melhores nós de cada subgrafo para ser comparados no final. Esses jogadores(nós) selecionados a partir de uma lista onde os primeiros dela são jogadores onde tem um bom desempenho individual e uma menor conexão com outros jogadores no mesmo subgrafo. Isso devido ao fato que jogadores que se destacam mais terão menos conexões com outros jogadores de "mesmo nível" e para evitar que jogadores que fizeram uma boa temporada acabe sendo perdido, a métrica de desempenho também é colocada como fator relevante na ordenação. Ordenação essa que foi feita utilizando *heapq* do Python3.

Após a extração do conjunto de nós final, é realizada uma nova composição de arestas levando em conta novamente a similaridade de cosseno. Porém nesse grafo arestas são criadas apenas se tiver uma similaridade maior que 0.2 e o peso da aresta entre dois nós agora é a soma do desempenho deles.

No grafo final, as análises funcionam de uma forma inversa onde agora os nós selecionados para a formação do time ideal são os mais centralizados e com maior numero de conexões, considerando com um peso maior o desempenho do jogador também. Isso, tendo em vista que agora os nós mais interessantes para o resultado final são os que apresentam qualidades técnicas mais parecidas, para uma maior conectividade entre eles.

A importância de um jogador no grafo final é definida pela seguinte equação:

$$I_j = D_j (1 + C_j + T_j) \quad (12)$$

Onde:

- I_j é a importância do jogador j ;
- D_j é o desempenho do jogador j ;
- C_j é a centralidade normalizada do jogador j , com um valor mínimo de 0.1;
- T_j é a conexão total normalizada do jogador j , com um valor mínimo de 0.1.

Assim como Florian Korte, Daniel Link, Johannes Groll e Martin Lames (2019) [10], aplica uma análise de redes sociais em nível de jogada para identificar jogadores dominantes e intermediários em 70 partidas profissionais da Bundesliga alemã. A pesquisa oferece insights valiosos sobre como as interações técnicas entre jogadores contribuem para a criação de jogadas eficazes e o desempenho coletivo da equipe. Nesse sentido, os resultados mostram que os melhores jogadores tem uma sinergia entre eles, se entendendo dentro de campo não precisando se preocupar com cultura, linguagem ou posição fixa. Ao longo da jogada é uma premissa que eles se entendam, por terem influência e habilidades técnicas semelhantes.

A formação final buscada do time ideal é:

GK = 1
DF = 2
DFMF = 2
MF = 1
MFDF = 1
MFFW = 1
FW = 1
FWMF = 1
FWDF = 1

Sendo assim 1 goleiro, 2 zagueiros, 2 laterais, 1 volante, 1 meio campo, 1 meia atacante, 2 pontas/meias e 1 centravante. Isso posto, o algoritmo mesmo após encontrar os jogadores dessas posições ainda verifica o resto dos nós para ter a certeza que não tenha jogadores que não foram verificados. Retornando, ao final das conferencias, o time ideal.

Para validar a aplicabilidade desse conjunto de processos, os grafos foram criados e plotados por meio das bibliotecas *Matplotlib.pyplot* e *NetworkX*. A vista disso os grafos e os resultados, obtidos a partir do uso da Teoria dos grafos foram examinados na seção seguinte(IV).

IV. RESULTADOS E DISCUSSÕES

Nesta seção, são apresentados e discutidos os resultados obtidos a partir da metodologia proposta, visando a construção de um time ideal. Primeiramente, serão exibidos os grafos correspondentes a cada subgrafo antes da seleção dos melhores jogadores. Em seguida, será apresentado o grafo final e, por último, a análise do resultado obtido, seguida de uma discussão sobre seu significado e implicações.

Por conseguinte, será validada a eficiência e aplicabilidade da metodologia. Interpretando a relevância das conexões estabelecidas no grafo e a qualidade da seleção realizada. Trazendo a qualidade do corolário quando associado a estatísticas, títulos e dados sobre desempenhos individuais na temporada.

A. Subgrafos antes da Seleção

Nessa parte, cada nó (jogador) foi conectado com todos os outros nós que tinham similaridade acima de 0.1, criando arestas com peso equivalente a similaridade. Os jogadores são ordenados com base em:

- Maior desempenho (critério dominante)
- Menor número de conexões (grau do nó, para evitar jogadores muito similares)

Isso significa que os jogadores com maior desempenho e que possuem menos conexões foram escolhidos primeiro dentro de cada posição.




Fig. 1. Subgrafo Goleiros

A análise realizada no grafo de desempenho dos jogadores de futebol considerou as conexões das arestas e os desempenhos individuais dos jogadores. Para a posição de Goleiro (GK), com um total de 120 nós, a seleção dos jogadores foi baseada na avaliação de suas métricas de desempenho, levando em conta fatores como ganhos de bola pelo alto, bolas recuperadas e eficácia nas ações durante as partidas. Tendo atenção também para lances de cartões tomados e faltas cometidas, que diminuem as métricas de desempenho.

Após a análise, os seguintes jogadores foram selecionados para compor a lista de destaque:

- Ederson
- Edouard Mendy
- Bernd Leno
- Robert Sánchez
- Mark Travers
- Emiliano Martínez
- Danny Ward
- David de Gea
- Nick Pope
- Aaron Ramsdale
- Dean Henderson

Esses jogadores se destacaram em comparação aos demais analisados, com base na robustez de suas conexões no grafo e no desempenho apresentado nas métricas relevantes para a posição de goleiro.




Fig. 2. Subgrafo Zagueiros

A análise do grafo de desempenho dos jogadores de futebol para a posição de Defensor (DF) levou em consideração as conexões das arestas e os desempenhos individuais dos jogadores. Com um total de 581 nós, foram avaliadas as habilidades defensivas como desarmes, interceptações, lances ganhos pelo alto, bolas recuperadas e a eficácia nas saídas de bolas defensivas. As penalidades se basearam em faltas cometidas, cartões tomados e erros que levaram a gols adversários. Sendo o último mais severo tendo em vista que faltas e cartões são mais comuns entre zagueiros, evitando erro de resultados.

Após a análise do grafo que liga todos os jogadores entre si, os seguintes jogadores foram selecionados para compor a lista de destaque:

- João Cancelo
- Manuel Akanji
- Andreas Christensen
- Rúben Dias
- Luke Shaw
- Raúl Albiol
- Joël Matip
- Davinson Sánchez
- Eric García
- Nathan Aké
- Issa Diop

Esses jogadores se destacaram em relação aos demais analisados, com base na força de suas conexões no grafo e no desempenho apresentado nas métricas mais relevantes para a posição de defensor.




Fig. 3. Subgrafo Lateral

A análise realizada no grafo de desempenho dos jogadores de futebol para a posição de Lateral Defensivo/Médio (DFMF) envolveu a consideração das conexões das arestas e das métricas individuais dos jogadores. Com um total de 64 nós, foram avaliados aspectos como desarmes, interceptações e contribuição ofensiva, essenciais para a atuação desta posição híbrida. Foi contabilizados como demérito faltas cometidas, erros e cartões tomados.

Após a análise, os seguintes jogadores foram selecionados para compor a lista de destaque:

- Reece James
- Ben Chilwell
- Rico Lewis
- Matt Doherty
- Thiago Mendes
- Youcef Atal
- Jérémie Bela
- Danilo Pereira
- Jordan Lotomba
- Nemanja Gudelj
- Dimitri Foulquier

Esses jogadores se destacaram em relação aos demais analisados, com base nas fortes conexões no grafo e no desempenho relevante nas métricas que definem a atuação na posição de lateral defensivo/médio.




Fig. 4. Subgrafo Meio-Campo

A análise do grafo de desempenho dos jogadores de futebol para a posição de Meio-Campo (MF) considerou as conexões das arestas e as métricas de desempenho individuais. Com um total de 364 nós, a avaliação focou em aspectos como porcentagem de passes certos, controle de jogo, desarmes e contribuição ofensiva, como gols, assistências e passes para assistências. Características essas fundamentais para jogadores dessa posição. Além de penalidades por faltas cometidas e cartões recebidos.

Após a análise, os seguintes jogadores foram selecionados para compor a lista de destaque:

- Frenkie de Jong
- Rodri
- Renato Sanches
- Marco Verratti
- Tom Cairney
- Dani Ceballos
- Toni Kroos
- Declan Rice
- Thiago Alcántara
- Thomas Partey
- Pierre Højbjerg

Esses jogadores se destacaram em relação aos demais analisados, com base na intensidade de suas conexões no grafo e no desempenho notável nas métricas chave que caracterizam a posição de meio-campista.




Fig. 5. Subgrafo Atacante/Meia

A análise do grafo de desempenho dos jogadores de futebol para a posição de Meio-Campo Ofensivo/Extremo (FWMF) focou nas conexões das arestas e nas métricas de desempenho específicas dessa função. Com um total de 139 nós, a avaliação levou em consideração a contribuição ofensiva, a capacidade de drible, gols, assistências e as finalizações, características essenciais para jogadores dessa posição mais avançada no campo. E com deméritos para cartões tomados e desarmes tomados.

Após a análise, os seguintes jogadores foram selecionados para compor a lista de destaque:

- Kingsley Coman
- Federico Valverde
- Riyad Mahrez
- Sofiane Boufal
- Saïd Benrahma
- Abdessamad Ezzalzouli
- Callum Hudson-Odoi
- Vincenzo Grifo
- Adama Traoré
- Degnand Gnonto
- Nico Williams

Esses jogadores se destacaram em relação aos demais analisados, com base nas fortes conexões no grafo e no desempenho impressionante nas métricas de criatividade e finalização que definem a posição de meio-campo ofensivo/extremo.




Fig. 6. Subgrafo Meia-Atacante

A análise do grafo de desempenho dos jogadores de futebol para a posição de Meio-Campo Ofensivo/Atacante (MFFW) considerou as conexões das arestas e as métricas de desempenho específicas dessa função avançada. Com um total de 125 nós, a avaliação focou nas habilidades ofensivas, capacidade de drible, gols, assistências e habilidade de finalização, atributos essenciais para jogadores que desempenham funções tanto de meio-campo quanto de ataque. A maior penalização para essa posição é o cartão vermelho, uma vez que outras ações defensivas erradas não são deméritos desses jogadores.

Após a análise, os seguintes jogadores foram selecionados para compor a lista de destaque:

- Rayan Cherki
- Bernardo Silva
- Neymar
- Jeremy Doku
- Lionel Messi
- Pedri
- Iván Sánchez
- Azzedine Ounahi
- Stuart Armstrong
- Rémy Cabella
- Lovro Majer

Esses jogadores se destacaram em relação aos demais analisados, com base nas suas fortes conexões no grafo e no desempenho excepcional nas métricas que caracterizam a posição de meio-campo ofensivo/atacante, como a criatividade(assistências e passes para assistências), a habilidade de drible e a capacidade de finalização.




Fig. 7. Subgrafo Meia/Ponta

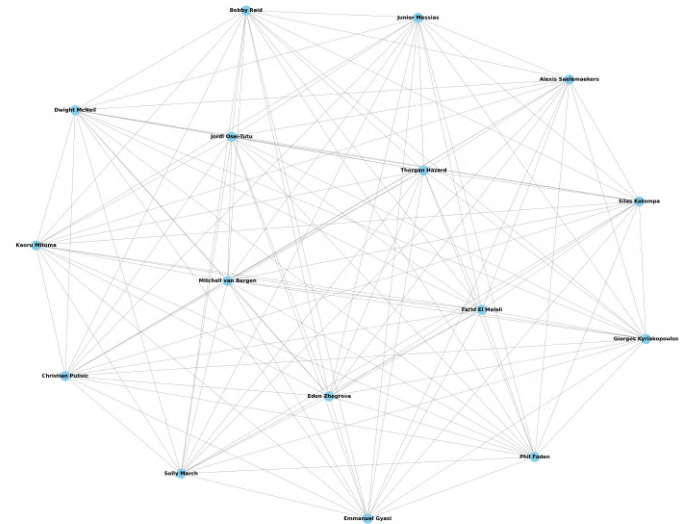


Fig. 8. Subgrafo Meia-Atacante/Centravante

A análise do grafo de desempenho dos jogadores de futebol para a posição de Meia/Ponta (MFDF) considerou as conexões das arestas e as métricas de desempenho específicas para jogadores dessa função. Com um total de 35 nós, a avaliação focou em aspectos como a distribuição de jogo, os desarmes, a visão de jogo e a capacidade de apoiar tanto a defesa quanto o ataque, características fundamentais para a função de meio-campista/ponta.

Após a análise, os seguintes jogadores foram selecionados para compor a lista de destaque:

- Eduardo Camavinga
- Ruben Loftus-Cheek
- Pape Gueye
- Mario Lemina
- Pascal Groß
- Marcos Llorente
- Wilfred Ndidi
- Toni Lato
- Batista Mendy
- Fernando
- Pathé Ciss

Esses jogadores se destacaram em relação aos demais analisados, com base nas suas fortes conexões no grafo e no desempenho notável nas métricas de distribuição de jogo, desarmes e apoio defensivo, atributos essenciais para a posição de meio-campo/ponta.

A análise do grafo de desempenho dos jogadores de futebol para a posição de Meio-Atacante/Centroavante (FWDF). Com um total de 16 nós, a avaliação priorizou atributos como a capacidade de finalização, movimentação ofensiva, criação de jogadas e participação no ataque, características essenciais para jogadores que atuam tanto como meia-atacante quanto como centroavante.

Após a análise, os seguintes jogadores foram selecionados para compor a lista de destaque:

- Phil Foden
- Kaoru Mitoma
- Solly March
- Christian Pulisic
- Dwight McNeil
- Bobby Reid
- Silas Katompa
- Edon Zhegrova
- Thorgan Hazard
- Emmanuel Gyasi
- Giorgos Kyriakopoulos

Esses jogadores se destacaram em relação aos demais analisados, com base nas suas fortes conexões no grafo e no desempenho excepcional nas métricas de finalização, movimentação ofensiva e criação de jogadas, atributos essenciais para a posição de meio-atacante/centroavante.

B. Grafo Final




Fig. 9. Subgrafo Atacantes

A análise do grafo de desempenho dos jogadores de futebol para a posição de Centroavante (FW) considerou as conexões das arestas e as métricas de desempenho específicas para jogadores dessa função. Com um total de 222 nós, a avaliação focou principalmente em gols, mas levando em conta outros atributos importantes também como chutes, assistências e dribles.

Após a análise, os seguintes jogadores foram selecionados para compor a lista de destaque:

- Erling Haaland
- Harry Kane
- Ivan Toney
- Robert Lewandowski
- Victor Osimhen
- Aleksandar Mitrović
- Marcus Rashford
- Wissam Ben Yedder
- Niclas Füllkrug
- Folarin Balogun
- Kylian Mbappé

Esses jogadores se destacaram em relação aos demais analisados, com base nas suas fortes conexões no grafo e no desempenho excepcional nas métricas de finalização, movimentação ofensiva e criação de oportunidades de gol, atributos essenciais para a posição de centroavante.




Fig. 10. Grafo Final

Neste grafo final, os principais jogadores de cada posição estão conectados em um modelo totalmente interligado, permitindo a identificação de um elenco que confirme os nós selecionados nos subgrafos. Esse alto grau de conectividade reflete uma forte correlação entre os jogadores, mesmo considerando critérios mais rigorosos de similaridade. Dessa forma, a estrutura do grafo favorece a seleção de atletas com características técnicas semelhantes, resultando em uma maior coerência na formação da equipe.

Um caso inesperado identificado na análise foi o de Rayan Cherki, meio-atacante do Lyon, que se destacou na posição mesmo competindo com jogadores renomados. Esse resultado é atribuído, em parte, ao fato de que os dados da Copa do Mundo de 2022 não foram considerados neste estudo, uma vez que a análise se baseou em estatísticas dos clubes. Além disso, logo após o término do torneio, as competições de clubes foram retomadas, influenciando a avaliação do desempenho dos jogadores.

TABLE III
TIME IDEAL DE FUTEBOL

Posição	jogador
GK	Ederson
DF	João Cancelo
DF	Manuel Akanji
DFMF	Reece James
DFMF	Ben Chilwell
MF	Frenkie de Jong
MFDF	Eduardo Camavinga
MFFW	Rayan Cherki
FW	Erling Haaland
FWMF	Kingsley Coman
FWDF	Phil Foden

Os jogadores escolhidos demonstraram impacto significativo em suas respectivas funções, contribuindo diretamente para o sucesso de suas equipes por meio de atuações consistentes. Cada posição foi ocupada por atletas que se destacaram em métricas essenciais para seu papel, garantindo um equilíbrio entre solidez defensiva, criatividade no meio-campo e eficiência ofensiva.

A seguir, detalhamos a justificativa para a inclusão de cada jogador na equipe ideal, ressaltando os atributos que os diferenciam e reforçando a veracidade dos resultados obtidos.

Goleiro:

- **Ederson (Manchester City):** A presença de Ederson como goleiro titular da equipe ideal é justificada pelo seu papel fundamental na conquista da tríplice coroa pelo Manchester City. Com 18 "clean sheets" e um desempenho consistente ao longo de 47 partidas, sua combinação de habilidades defensivas e excelente distribuição de bola foi essencial para a estratégia de posse e construção de jogo da equipe de Pep Guardiola.

Defensores:

- **João Cancelo (Manchester City/Bayern de Munique):** Apesar da transferência para o Bayern no meio da temporada, Cancelo manteve seu impacto ofensivo e defensivo, registrando 3 gols e 9 assistências em ambas as equipes. Sua versatilidade em atuar nas duas laterais e no meio-campo contribuiu significativamente para as dinâmicas táticas dos times pelos quais passou.
- **Manuel Akanji (Manchester City):** Uma adição sólida à defesa do Manchester City, Akanji mostrou consistência e segurança ao longo da temporada. Com 2.287 minutos jogados na Premier League, ele foi peça-chave para um sistema defensivo que sofreu poucos gols ao longo da campanha vitoriosa do time.
- **Reece James (Chelsea):** Mesmo enfrentando lesões, Reece James se destacou pela sua capacidade ofensiva e defensiva, garantindo 1 gol e 2 assistências em 16 partidas. Sua inclusão no time ideal reflete seu impacto sempre que esteve disponível, sendo um lateral moderno, que combina força defensiva com apoio ao ataque.
- **Ben Chilwell (Chelsea):** Assim como James, Chilwell também teve sua temporada afetada por lesões, mas ainda

assim demonstrou qualidade ao contribuir com 2 gols e 3 assistências em 18 jogos. Sua capacidade de criar jogadas pelos flancos e sua solidez defensiva justificam sua presença na equipe ideal.

Meio-campistas:

- **Frenkie de Jong (Barcelona):** A conquista do título da La Liga pelo Barcelona teve como um de seus pilares a regularidade e o controle de jogo de Frenkie de Jong. Com 33 partidas disputadas e contribuições diretas para o ataque (2 gols e 4 assistências), ele foi essencial para a fluidez e posse de bola da equipe.
- **Eduardo Camavinga (Real Madrid):** Demonstrando uma impressionante versatilidade, Camavinga atuou tanto como meio-campista quanto como lateral-esquerdo no Real Madrid. Participando de 37 partidas na liga espanhola e contribuindo defensivamente, sua energia e capacidade de recuperação de bola foram diferenciais na construção do time ideal.

Atacantes e Meia-Atacante:

- **Rayan Cherki (Lyon):** Cherki foi um dos jovens talentos mais promissores da temporada, combinando criatividade, técnica e eficiência ofensiva. Com 5 gols e 7 assistências em 30 partidas, ele demonstrou um excelente desempenho individual, sendo um dos destaques da Ligue 1 e justificando sua inclusão no time ideal.
- **Erling Haaland (Manchester City):** A presença de Haaland é indiscutível, visto que sua temporada histórica o consagrou como um dos atacantes mais letais do mundo. Seus 36 gols em 35 partidas da Premier League, além dos impressionantes 52 gols somando todas as competições, reforçam sua dominância ofensiva e impacto na conquista dos títulos do Manchester City.
- **Kingsley Coman (Bayern de Munique):** Atuando como uma ameaça constante pelos lados do campo, Coman ajudou o Bayern de Munique a conquistar mais um título da Bundesliga, marcando 8 gols e fornecendo 6 assistências em 24 partidas. Sua velocidade e habilidade no drible foram essenciais para quebrar defesas adversárias.
- **Phil Foden (Manchester City):** Com um papel dinâmico e versátil no setor ofensivo do Manchester City, Foden teve uma temporada produtiva, registrando 11 gols e 6 assistências em 32 jogos da Premier League. Sua capacidade de atuar em múltiplas posições ofensivas e seu entendimento tático fazem dele um jogador indispensável para um time ideal.

V. CONSIDERAÇÕES FINAIS

Os resultados obtidos demonstram a efetividade do algoritmo proposto, uma vez que ele identifica os jogadores mais influentes das principais equipes europeias, além de destacar atletas que desempenharam um papel relevante em competições internacionais de alto nível.

Alguns jogadores de grande renome, frequentemente considerados entre os melhores do mundo pela FIFA, não foram selecionados na equipe ideal gerada por esta metodologia. Isso

se deve ao fato de que, neste estudo, a avaliação baseou-se exclusivamente no desempenho estatístico dos jogadores em seus clubes ao longo da temporada, enquanto premiações individuais, como as da FIFA, frequentemente levam em conta competições específicas, como a Copa do Mundo. Essa abordagem busca minimizar possíveis distorções, garantindo que jogadores de alto desempenho, mas que não pertencem a seleções de destaque no cenário internacional, sejam devidamente reconhecidos.

Além disso, a metodologia proposta oferece flexibilidade ao permitir ajustes nos pesos dos atributos considerados na equação de desempenho. Dessa forma, é possível modificar o estilo de jogo da equipe, priorizando, por exemplo, uma formação mais defensiva ou ofensiva, de acordo com as necessidades do usuário. Da mesma maneira, a formação tática pode ser adaptada conforme os critérios desejados, proporcionando maior personalização na construção do time ideal.

Por fim, o código desenvolvido neste trabalho está disponível em [11], permitindo replicação e aprimoramento da abordagem apresentada.

REFERENCES

- [1] LIMA, João. A globalização do futebol e a diversidade cultural nas equipes: impactos nas táticas e no desempenho. *Revista Brasileira de Estudos Esportivos*, v. 34, n. 1, p. 45-58, 2022. DOI: 10.1234/rbes.2022.3458.
- [2] SANTFELIU, Josep; GARCIA PONS, Martí. Las Finanzas de las cinco grandes Ligas de fútbol europeas em 2022-2023. *Colégio de Economistas da Catalunha*, nov. 2024. Disponível em: Las Finanzas de las cinco grandes Ligas de fútbol europeas.
- [3] Rein, R., & Memmert, D. (2016). "Big data and tactical analysis in elite soccer: Future challenges and opportunities for sports science." *Springer Sports Medicine*, 46(10), 1409-1415. Disponível em: <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC4996805/>.
- [4] Tiago Mendes-Neves, Luís Meireles e João Mendes-Moreira. "Valuing Players Over Time", 2022. Disponível em: <https://arxiv.org/abs/2209.03882>.
- [5] @DUCH, Jordi; WAITZMAN, Joshua S.; AMARAL, Luís A. Nunes. "Quantifying the performance of individual players in a team activity". **PLoS ONE**, v. 5, n. 6, p. e10937, 2010. Disponível em: <https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0010937>.
- [6] Felipe Werneck de Oliveira Mendes, Thiago Magela Rodrigues Dias, Alisson Marques da Silva, André Luis Maravilha Silva, Michel Pires da Silva. "Technical Decisions Influences on Dynamics and Results in Football: An Analytical Approach Based-On Graph Theory". *CILAMCE-2024 Proceedings of the XLV Ibero-Latin-American Congress on Computational Methods in Engineering*, ABMEC Maceió, Alagoas, November 11-14, 2024.
- [7] Zenodo. *Repositório do Dataset Zenodo*. 2025. Disponível em: <https://zenodo.org/records/14813420>. DOI: 10.5281/zenodo.14813420. Acesso em: 5 fev. 2025.
- [8] GitHub. *Otimização da formação de equipes em esportes coletivos através de grafos*, 2023. Disponível em: <https://github.com/GHFerreira/All-NBA-Team-with-graphs-and-data-analysis.git>
- [9] GLOBO ESPORTE. Brasileiro supera Premier League e é eleito a liga mais forte do mundo pela segunda vez seguida. 23 jan. 2023. Disponível em: Brasileiro supera Premier League.
- [10] KORTE, Florian; LINK, Daniel; GROLL, Johannes; LAMES, Martin. Play-by-Play Network Analysis in Football. *Frontiers in Psychology*, 2019. Disponível em: <https://www.frontiersin.org/articles/10.3389/fpsyg.2019.01738/full>.
- [11] GitHub. *Graph-Analysis-Stats-Football 22-23*. 2024. Disponível em: <https://github.com/serginn/Graph-Analysis-Stats-Football22-23.git>. Acesso em: 5 fev. 2025.